智能搜索问答方案（V3 版本）部署指引

一、部署文件上传：

a. 海外区域：打开 cloud9，上传部署文件到 cloud9，并解压部署文件

b. 国内区域：新建 EC2 后，上传部署文件到 EC2，并解压部署文件，执行以下脚本，安装 npm 和 node：

- `curl -o- https://raw.githubusercontent.com/nvm-sh/nvm/v0.39.3/install.sh | bash`
- `nvm install node`

二、通过部署 cdk 部署 lambda、opensearch(或 Kendra)和 Notebook 服务

1、修改部署配置，打开 deployment /cdk.json 文件

1. 如果需要部署 Kendra，修改 search_engine_kendra 为 true，search_engine_opensearch 为 false。
2. 如果只部署智能问答功能，selection 参数仅保留"langchain_processor_qa"选项，其余选项去除。

2、 打开 Terminal，进入 deployment 目录，依次运行以下命令部署

1. pip install -r requirements.txt
2. export AWS_ACCOUNT_ID=替换实际参数
3. export AWS_REGION=替换实际参数

以下两项需要在 EC2 环境执行，cloud9 环境跳过：

(1)export AWS_ACCESS_KEY_ID=替换实际参数

(2)export AWS_SECRET_ACCESS_KEY=替换实际参数

4. cdk bootstrap
5. cdk deploy --all

三、部署向量模型和开源大语言模型

中文：

1. 在 Amazon Sagemaker Notebook, 找到 SmartSearchNotebook
2. 通过 Embedding_Model/chinese_bge_large_zh/chinese_bge_large_zh_deploy.ipynb 部署中文向量模型
3. 部署大语言模型：
   进入 LLM_Model/ llm-baichuan, 运行 main.ipynb

英文：

1．在 SageMaker->Notebook->Notebook instances，找到 SmartSearchNotebook，点击 Open Jupyter

2．部署向量模型：运行
Embedding_Model/chinese_bge_large_en/english_bge_large_zh_deploy.ipynb
3. 部署大语言模型
vicuna1.5:

(1) 打开 LLM_Model/llm-english/code/inference.py，把 37 行的 LLM_NAME 的值改为” lmsys/vicuna-7b-v1.5”

(2) 运行 LLM_Model/llm-english/llm_english_sagemaker_byos.ipynb 部署模型

llama2(可选)：

（1）在 Sagemaker 页面打开 Studio

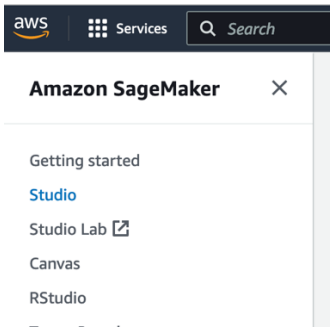

（2）进入 Studio 后，打开 SageMaker JumpStart，点击“Llama-2-7b-chat”

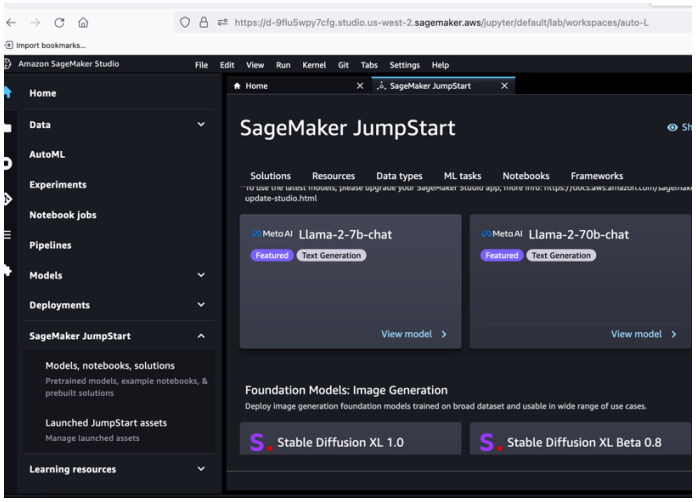

（3）点击 Deploy 部署

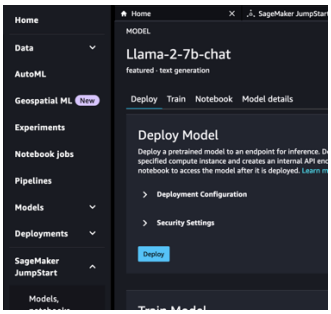

四、数据导入

1. 在 S3 查找 intelligent-search-data-bucket-ACCOUNT-REGION 分桶，新建 source_data 目录，并上传文件。可以在 cloudWatch 的 Log groups 查找 langchain_processor_dataload，查看文件导入情况。成功导入会输出文件导入时间和文件名

```
File import takes time: 0:00:27.171235
```

```
Complete the import of the following documents: ['/tmp/基于预训练语言模型的行业搜索的应用和研究.docx']
```

2. 在 Notebook 文件导入：
   S3 数据导入不能更改数据导入的 index 和 language 等参数，建议使用 Notebook 导入，相比 S3 数据导入更灵活。
   （1）在 SageMaker->Notebook->Notebook instances，找到 SmartSearchNotebook，点击 Open Jupyter
   （2）打开 data_load/data_load.ipyn,在第 3 个代码框中，修改 index、language 和 EMBEDDING_ENDPOINT_NAME 参数。其中 index 为导入数据的 index 名称，可以自定义，language 为导入文件的语言，EMBEDDING_ENDPOINT_NAME 为上面部署的向量模型的 endpoint name,在 Sagemaker ->Inference -> Endpoints 页面可以找到
   （3）在 isearchjupyter 文件夹下新建一个文件夹，上传需要导入的文件
   （4）在第 3 个代码框中，修改 local_file 参数，替换为需要导入的文件路径。依次运行代码框以导入文件。

五、数据验证

1. API 测试，进入 API Gateway，点击 smart-search-qa-api，在 Resources 下点击 GET，再点击旁边的 TEST，进入测试页面

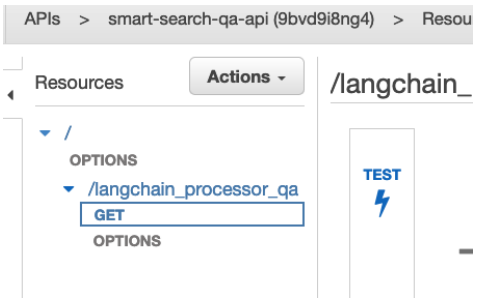

2. 在 Qurey Strings 下输入查询文本 query=你好&task=chat：

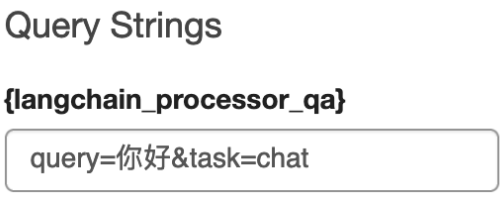

3. 稍等约 10 多秒后，右边输出 Status:200 表示运行成功

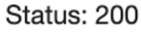

4. 点击左边栏的 Stages -> Prod，找到右边的 Invoke URL 并拷贝

5. 进入 gradio-web 目录，点击 gradio-webpage.py，将 Invoke URL 替换 invoke_url 变量。同时配置 index、embedding_endpoint、llm_endpoint 参数，如果只部署了一个语种的 embdding model 和 llm, 仅需配置相应的参数。
6. 安装 gradio：pip install -r requriments.txt
7. 运行 gradio-webpage.py，运行后生成一个本地 URL 地址和公共 URL 地址，公共 URL 地址能分享给其他人测试

```
(/home/ec2-user/environment/web_test/python3.9_env) Admin:~/environment/web_test $ python gradio_test.py
Running on local URL:  http://127.0.0.1:7860
Running on public URL: https://4d23740206bfdb0c0d.gradio.live
```

测试页面的有效时间是 72 小时，页面过期后需重新生成

8. 在本地浏览器打开公共 URL 地址后测试

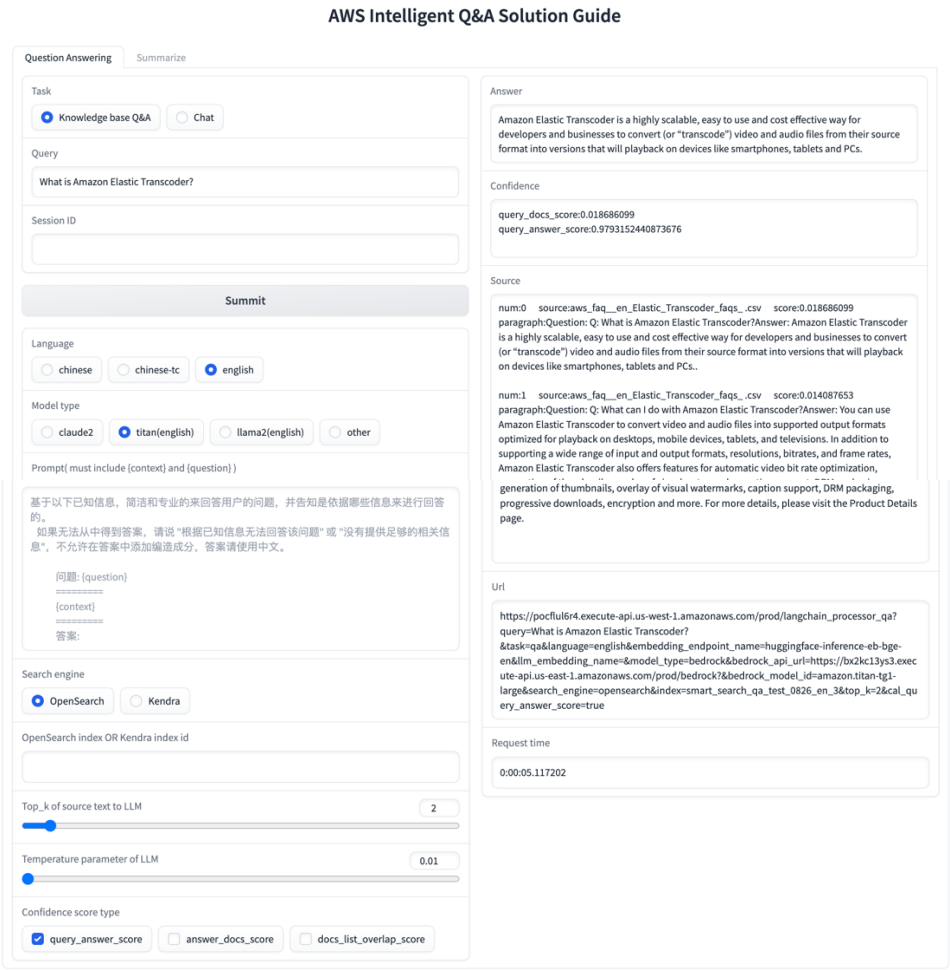

页面左边为参数输入部分，除 Query 外，其余参数可以不用输入，使用默认值。

其余参数说明如下：

1.Task:

(1)Knowledge base Q&A: 基于知识库的问答

(2)Chat: 聊天

2.Session ID

输入 Session ID 后，对话的问题和答案将会被记录下来，用于实现多轮对话功能。如要要使用基于知识库的多轮对话，请输入一个随机的字符串作为 Session ID，如果要结束本轮对话，去除当前 Session ID 或换另外字符串作为新的 Session ID 即可。

3.Language

(1)chinese --- 简体中文

(2)chinese-tc --- 繁体中文

(3)english --- 英语

4.Model type

(1)claude2: 目前支持调用 Bedrock 的 claude2 模型，该模型同时支持中文和英文

(2)Titan: 目前支持调用 Bedrock 的 Titan 模型,该模型目前只支持英文

(3)llama2: 目前支持通过 jumpstart 部署的了 llama2 模型，该模型建议只在英文场景使用

(4)other: chatglm2 等中文大语言模型

5.Prompt

prompt 是提示词，方案有使用默认提示词，如需对提示词修改调优，中文需要保留{question}和{context}字段，修改其他字段。英文不需要{question}和{context}字段。

6.Search engine

方案支持 2 种搜索引擎，分别为 OpenSearch 和 Kendra.

7.OpenSearch index OR Kendra index id

如果 Search engine 选择为 OpenSearch, 该参数为 OpenSearch 的 index。如果 Search engine 选择为 Kendra, 该参数为 Kendra 的 index id。

8.Top_k of source text to LLM

查找与问题相关的文档数量，查找到的相关文档将组合成 Prompt 后送到大模型推理。

9.Temperature

大语言模型的 temperature 参数

10.Confidence score type

计算答案置信度分数类型：

query_answer_scoer: 计算问题与答案的相似度

answer_docs_score:计算答案与相关文档的相似度

docs_list_overlap_score:计算问题相关文档与答案相关文档的重合率

右边为输出部分：

1.Answer

大模型根据问题生成的答案

2.Confidence

根据 Confidence score type 选择的计算类型，输出答案置信度的计算结果

3.Source

根据问题找到的相关文档，输出相关文档的来源标题、相关分数和具体文本内容。

4.Url

请求的 Url，用于检查请求参数是否正确。

5.Request time

请求时长。

如果通过 API 调用，API 可用的参数为：

序号	参数名	默认值	说明

1	query	hello	输入的问题
2	task	qa	1.qa：基于知识库的问答 2.chat：基于模型的问答 3.summarize：基于给定文档的创意文本生成
3	index	smart_search_qa_test	根据需求更改
4	language	chinese	1.chinese --- 简体中文 2.chinese-tc --- 繁体中文 3.english --- 英语
5	temperature	0.01	大模型的参数，控制答案生成的随机性
6	embedding_endpoint_name	huggingface-inference-eb	向量模型的 endpoint 名字
7	llm_embedding_name	pytorch-inference-llm-v1	大语言模型的 endpoint 名字
8	search_engine	opensearch	支持 opensearch 和 kendra 共 2 种搜索引擎
9	kendra_index_id	kendra 部署后自动将 index id 同步为默认值	根据需求修改
10	session_id	无	多轮对话使用，可以为随机字符串
11	prompt	可查看 lambda/longchain_processor_qa/prompy.py 文件	根据需求修改
12	chain_type	stuff	在 task=summarize 时使用，可以使用 map_reduce 对文档分段处理后再合并处理
13	combine_prompt	可查看 lambda/longchain_processor_qa/prompy.py 文件	在 task=summarize and chain_type=map_reduce 时使用
14	top_k	2	根据需求修改
15	cal_query_answer_score	FALSE	是否计算 query_answer_score
16	cal_answer_docs_score	FALSE	是否计算 answer_docs_score
17	cal_docs_list_overlap_score	FALSE	是否计算 cal_docs_list_overlap_score
18	response_type	无	web_ui：返回到 React 前端页面数据结构 其他：返回到 gradio 前端页面数据结构
19	model_type	other	1.bedrock: 调用 bedrock 的大语言模型接口 2.llama2:调用 llama2 模型 3.other:调用其他模型
20	bedrock_api_url	无	调用 bedrock 服务的 API URL， 参数在 model_type=bedrock 时使用
21	bedrock_model_id	anthropic.claude-v2	1.anthropic.claude-v2：调用 claud2 模型 2.amazon.titan-tg1-large：调用 titan 模型 参数在 model_type=bedrock 时使用
22	bedrock_max_tokens	512	调用 bedrock 大语言模型时，答案的最大生成 token 数

调用示例可以参考 gradio 页面的 Url。

六、多轮问答网页

需要验证多轮问答效果的场景，可以使用 chatbot_demo.py 前端页面，使用方式如下：

1. 打开 chatbot_demo.py，修改 invoke_url、index、embedding_endpoint 和 llm_endpoint
2. 把 chatbot_demo.py 下载到本地电脑，部署 streamlit:
   pip install streamlit
3. 运行：streamlit run chatbot_demo.py, 本地浏览器自动打开页面，可以在下面的输入框中输入问题：

4. 如果切换语言或任务参数，或重新起一个聊天 session，需要点击左下的“Claer Chat History”.